

Modellierung, Simulation und Regelung einer sensorlosen PMSM mit Reinforcement Learning und neuronalen Netzen

Link: <https://ieeexplore.ieee.org/document/10047821>

Projektbeschreibung

Entwicklung und Simulation eines **sensorlosen Field-Oriented-Control-Ansatzes (FOC)** für eine Interior Permanent Magnet Synchronous Motor (IPMSM) unter Verwendung von **künstlichen neuronalen Netzen (ANN)**, **Proportional-Integral-Regelung (PI)** und **Reinforcement Learning (RL)**.

Ziel war die Realisierung eines schnellen und effizienten Motorverhaltens bei gleichzeitiger Reduzierung des Bedarfs an physischen Sensoren für die Erfassung von Rotorposition und Drehzahl. Hierzu wurde ein tiefes neuronales Netz zur Schätzung von Rotorposition und Drehzahl entwickelt. Ergänzend wurde der **Twin Delayed Deep Deterministic Policy Gradient (TD3)**-Algorithmus eingesetzt, um die Regelungsstrategie des Motors zu optimieren.

Systemkomponenten

- **Sensorlose Feldorientierte Regelung (FOC):** Umsetzung einer FOC-Regelung für eine Interior-PMSM ohne physische Sensoren zur Erfassung von Rotorposition und Drehzahl.
- **Reinforcement Learning:** Implementierung des **TD3-Algorithmus** mit Actor-Critic-Netzwerken zur Optimierung der Regelungsstrategie.
- **Künstliches neuronales Netz:** Vier Hidden Layers mit **tanh-Aktivierungsfunktion in der ersten Schicht** und **ReLU-Aktivierungsfunktionen in den nachfolgenden Schichten** zur Schätzung von Rotorposition und Drehzahl.
- **PI-Regler:** Implementierung eines PI-Reglers mit anwendungsspezifischen proportionalen und integralen Parametern.
- **Simulation und Parameteranalyse:** Vergleich verschiedener Netzwerk- und RL-Konfigurationen anhand des resultierenden Motorverhaltens.

Technische Herausforderungen und Lösungsansätze

1. Auswahl des Reinforcement-Learning-Algorithmus

Eine zentrale Herausforderung bestand in der Auswahl einer RL-Methode, die eine hohe Regelungsgenauigkeit bei gleichzeitig reduzierter Varianz während des Trainings ermöglicht.

Hierfür wurde **TD3** eingesetzt. Der Algorithmus adressiert das bei DDPG auftretende Overestimation-Problem. Durch die Verwendung von begrenztem Rauschen bei den Aktionen wurde zusätzlich die Robustheit verbessert und die Varianz während des Trainings reduziert.

2. Entwicklung der neuronalen Netzwerkarchitektur

Bei der Entwicklung der ANN-Architektur musste ein Kompromiss zwischen Rechenaufwand und Schätzgenauigkeit berücksichtigt werden.

Das implementierte Netzwerk verfügt über **vier Eingangsneuronen und vier Hidden Layers**. Für das Training des neuronalen Netzes wurde der **Adam-Optimierer** verwendet.

3. Optimierung der Modellparameter

Zur Untersuchung des Motorverhaltens wurden verschiedene PMSM-Regelungskonfigurationen simuliert. Dabei wurden unter anderem die **Anzahl der Layer, die Anzahl der Neuronen, die Reward-Funktionen und die Optimierungsverfahren** variiert.

Die Untersuchung zeigte, dass eine Erhöhung der Anzahl der Neuronen im Vergleich zu den anderen getesteten Konfigurationen zu einem verbesserten Ansprechverhalten führte. Das entsprechende Modell erreichte die Referenzdrehzahl **10–25 ms früher** als die anderen im gleichen Simulationsumfeld untersuchten Modelle.

Ergebnis

Der entwickelte sensorlose PMSM-Regelungsansatz kombiniert **ANN-basierte Schätzung von Rotorposition und Drehzahl mit TD3-Reinforcement-Learning und PI-Regelung**.

Die durchgeführte Parameteranalyse zeigte eine Verbesserung der Annäherung an die Referenzdrehzahl. Die untersuchte Konfiguration mit einer höheren Anzahl an Neuronen erreichte die Referenzdrehzahl **10–25 ms früher** als die anderen getesteten Modelle.

Publikation: IEEE Xplore, International Conference 2022

Titel: *Improved FOC and Speed Estimation of PMSM using Reinforcement Learning and Neural Networks.*

Modelling, Simulation and Control of a Sensorless PMSM using Reinforcement Learning and Neural Networks

Project Description

Development and simulation of a **sensorless Field-Oriented Control (FOC)** approach for an Interior Permanent Magnet Synchronous Motor (IPMSM) using **Artificial Neural Networks (ANN), Proportional-Integral (PI) control, and Reinforcement Learning (RL)**.

The objective was to achieve a high-speed and efficient motor response while eliminating the need for physical rotor-position and speed sensors. A deep neural network was developed to estimate the rotor position and speed, thereby reducing system complexity and sensor requirements. In parallel, a **Twin Delayed Deep Deterministic Policy Gradient (TD3)** reinforcement-learning algorithm was implemented to optimise the motor-control policy.

System Components

- **Sensorless Field-Oriented Control:** FOC implementation for an Interior PMSM without physical rotor-position and speed sensors.
- **Reinforcement Learning:** Implementation of the **TD3** algorithm using actor–critic networks to optimise the control policy.

- **Artificial Neural Network:** Four hidden layers using **tanh activation in the initial layer and ReLU in the subsequent layers** for rotor-position and speed estimation.
- **PI Controller:** Implementation of a PI controller with application-specific proportional and integral parameters.
- **Simulation and Parameter Evaluation:** Comparison of different network and RL configurations based on motor response.

Technical Challenges and Solutions

1. Selection of the Reinforcement-Learning Algorithm

A key challenge was selecting an RL method that provided accurate control while maintaining reduced training variance. **TD3** was selected because it addresses the overestimation problem associated with DDPG. The use of clipped noise in the action selection was applied to improve robustness and reduce training variance.

2. Neural-Network Architecture

The ANN architecture had to balance computational complexity with estimation accuracy. The implemented network uses **four input neurons followed by four hidden layers**. The neural network was trained using the **Adam optimiser**.

3. Parameter Optimisation

Different PMSM control configurations were evaluated by varying parameters such as the **number of layers, number of neurons, reward functions, and optimisation methods**.

The evaluated configurations showed that increasing the number of neurons improved the motor response compared with the other tested configurations. The selected model reached the reference speed **10–25 ms earlier** than the other models evaluated in the same simulation environment.

Result

The developed sensorless PMSM control approach demonstrated the application of **ANN-based rotor-position and speed estimation combined with TD3 reinforcement learning and PI control**. The parameter study showed an improvement in reference-speed convergence, with the evaluated higher-neuron configuration reaching the reference speed **10–25 ms earlier** than the other tested models.

Publication: IEEE Xplore, 2022 International Conference

Paper: *Improvise FOC and Speed Estimation of PMSM using Reinforcement Learning and Neural Networks*